山东师范大学

本 科 毕 业 论 文

论文题目：基于脑电运动想象的脑机接口系统研究

学生姓名：黄昱峰

学　　号：**202211000139**

专　　业：计算机科学与技术专业

指导教师：王红

学　　院：信息科学与工程学院

2026 年 5 月 15 日

独　创　声　明

本人声明所呈交的学位论文是本人在导师指导下进行的研究工作及取得的研究成果。据我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得_____（注：如没有其他需要特别声明的，本栏可空）或其他教育机构的学位或证书使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示谢意。

学位论文作者签名：　　导师签字：

学位论文版权使用授权书

本学位论文作者完全了解__学校__有关保留、使用学位论文的规定，有权保留并向国家有关部门或机构送交论文的复印件和磁盘，允许论文被查阅和借阅。本人授权__学校__可以将学位论文的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存、汇编学位论文。（保密的学位论文在解密后适用本授权书）

学位论文作者签名：　　导师签字：

签字日期：2026 年 5 月 27 日　　签字日期：2026 年 5 月 27 日

目 录

摘要 ····· I
Abstract ····· II
5 特征提取与分类算法 ····· 1
5.1 共空间模式基线方法 ····· 1
5.1.1 CSP 算法原理 ····· 1
5.1.2 CSP 空间模式的物理含义 ····· 2
5.1.3 LDA 分类器 ····· 2
5.2 滤波器组共空间模式改进方法 ····· 3
5.2.1 FBCSP 的动机 ····· 3
5.2.2 FBCSP 算法流程 ····· 3
5.2.3 FBCSP 特征选择结果分析 ····· 4
5.2.4 SVM-RBF 分类器 ····· 6
5.3 EEGNet 深度学习对照方法 ····· 6
5.3.1 引入动机与定位 ····· 6
5.3.2 EEGNet 网络架构 ····· 6
5.3.3 训练策略 ····· 7
5.4 三种方法的对比分析 ····· 8

6 实验结果与分析 ····· 8
6.1 实验设置 ····· 9
6.1.1 数据集 ····· 9
6.1.2 预处理 ····· 10
6.1.3 评估协议 ····· 11
6.2 主实验：BCI Competition IV Dataset 2a ····· 11
6.2.1 逐被试分类结果 ····· 11
6.2.2 性能分布与 ROC 分析 ····· 12
6.2.3 CSP 空间模式与 ERD/ERS 分析 ····· 12
6.3 泛化验证一：BCI Competition IV Dataset 2b（通道受限） ····· 15
6.3.1 逐被试分类结果 ····· 15
6.3.2 关键观察 ····· 16
6.4 泛化验证二：PhysioNet EEGBCI（数据量不足） ····· 16
6.4.1 逐被试分类结果 ····· 16
6.4.2 关键观察 ····· 16
6.5 跨数据集对比分析 ····· 18
6.5.1 三数据集汇总对比 ····· 18
6.5.2 通道数对性能的影响 ····· 20
6.5.3 训练数据量的影响 ····· 20
6.6 统计检验 ····· 21
6.6.1 各数据集内的统计检验 ····· 21
6.6.2 跨数据集全局检验 ····· 23
6.7 综合讨论 ····· 23
6.7.1 在线仿真系统的算法选型依据 ····· 23

6.7.2 方法适用性的一般规律 ····· 24
6.7.3 EEGNet 可行性探针的实验回答 ····· 24
6.7.4 被试间差异与 BCI 文盲现象 ····· 24
6.7.5 与文献结果的对比 ····· 25
6.8 本章小结 ····· 25
参考文献 ····· 27
附录 ····· 30
致谢 ····· 31

摘要

中文摘要与关键词：对毕业论文（设计）核心内容的集中陈述，简要说明研究目的、研究方法、主要结果（结论），150 － 300 字，中文摘要后需列出 3-5 个关键词。（中英文摘要合起来尽量独占一页，如果内容较多也可占据两页）

关键词：脑机接口；运动想象；脑电信号

Abstract

The content of the English abstract should be basically the same as that of the Chinese abstract, and the English keywords corresponding to the Chinese keywords should be listed after the English abstract.

Key words: Brain-Computer Interface; Motor Imagery; EEG Signal

5 特征提取与分类算法

本章详细介绍三种运动想象分类方法的实现：共空间模式（CSP）结合线性判别分析（LDA）的基线方案、滤波器组共空间模式（FBCSP）结合支持向量机（SVM）的改进方案，以及 EEGNet 卷积神经网络的深度学习方案。三种方法在特征表示和学习策略上各有侧重，通过对比分析可以揭示不同技术路线在运动想象脑机接口中的优势与局限。

5.1 共空间模式基线方法

5.1.1 CSP 算法原理

共空间模式（Common Spatial Patterns, CSP）是运动想象脑机接口中最经典的空间滤波算法[1]。其核心思想是：寻找一组空间滤波器，使滤波后信号在一类运动想象条件下方差最大，同时在另一类条件下方差最小，从而最大化两类信号的可区分性。

设二分类问题中两类试次的 EEG 数据分别为 $\mathbf{X}_1 \in \mathbb{R}^{C\times T}$ 和 $\mathbf{X}_2 \in \mathbb{R}^{C\times T}$，其中 C 为通道数，T 为时间采样点数。首先计算两类数据的归一化空间协方差矩阵：

$$\mathbf{R}_i = \frac{1}{N_i}\sum_{n=1}^{N_i}\frac{\mathbf{X}_i^{(n)}\mathbf{X}_i^{(n)\top}}{\mathrm{tr}(\mathbf{X}_i^{(n)}\mathbf{X}_i^{(n)\top})}, \quad i \in \{1,2\} \tag{1}$$

其中 N_i 为第 i 类的试次数量，$\mathrm{tr}(\cdot)$ 表示矩阵的迹。

CSP 通过求解以下广义特征值问题获得空间滤波器矩阵 $\mathbf{W}$：

$$\mathbf{R}_1\mathbf{w} = \lambda(\mathbf{R}_1 + \mathbf{R}_2)\mathbf{w} \tag{2}$$

直觉上理解，这个公式做的事情是：在所有可能的”观察角度”（空间滤波器）中，找到能最大化两类脑电信号差异的那几个角度。特征值 λ 衡量的是这个”差异程度”——λ 越接近 1，说明从该角度看，第一类信号的能量占比越高（左手想象更活跃）；λ 越接近 0，则第二类信号的能量占比越高（右手想象更活跃）。实际使用时，选取两端各 m 个特征向

量（本文取 $m = 2$，共 4 个分量），构成投影矩阵 $\mathbf{W} \in \mathbb{R}^{2m \times C}$。这 4 个分量分别对应两个最能突出左手想象的空间模式和两个最能突出右手想象的空间模式。

对任一试次 $\mathbf{X}$，CSP 特征提取过程为：

$$\mathbf{Z} = \mathbf{W}\mathbf{X}, \quad f_j = \log \frac{\mathrm{var}(\mathbf{z}_j)}{\sum_{k=1}^{2m} \mathrm{var}(\mathbf{z}_k)}, \quad j = 1, \ldots, 2m \tag{3}$$

其中 $\mathbf{z}_j$ 为 $\mathbf{Z}$ 的第 j 行，f_j 为归一化对数方差特征。简言之，CSP 特征就是" 从不同空间角度观测到的脑电能量占比"——左手想象时，对应左手的分量能量占比高；右手想象时则相反。对数变换使特征近似服从正态分布，有利于后续分类器的处理[2]。

5.1.2 CSP 空间模式的物理含义

CSP 得到的空间模式（spatial patterns）可以投射到头皮拓扑图上，其分布反映了运动想象过程中大脑皮层的激活特征。图5-1展示了被试 1 的 CSP 空间模式。

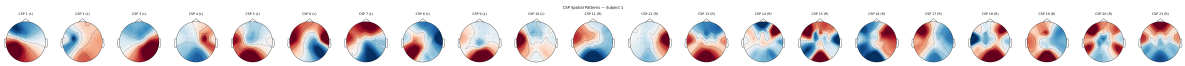

图 5-1 被试 1 的 CSP 空间模式脑地形图（4 个分量）
Fig. 5-1 CSP spatial patterns topography for Subject 1 (4 components)

从图中可以观察到，前两个分量（CSP 1、CSP 2）在对侧运动皮层区域（C3/C4 附近）呈现明显的极性分布，这与运动想象引起的事件相关去同步（ERD）现象相符[3]：左手想象主要激活右侧运动皮层，右手想象则主要激活左侧运动皮层。

5.1.3 LDA 分类器

线性判别分析（Linear Discriminant Analysis, LDA）[4] 是 CSP 特征的经典配套分类器。LDA 假设两类数据服从相同协方差的高斯分布，寻找使类间散度与类内散度之比最大的投影方向。CSP 提取的对数方差特征维度较低（本文为 4 维），且近似满足正态分布假设，因此 LDA 能够高效地完成分类任务。

本文采用的 CSP+LDA 基线方案参数配置如下：CSP 分量数为 4（即 $2m = 4$），带通

滤波频段为 8–30 Hz（覆盖 Mu 和 Beta 节律），LDA 使用 scikit-learn[5] 默认实现，采用自动收缩（shrinkage）正则化。

5.2 滤波器组共空间模式改进方法

5.2.1 FBCSP 的动机

标准 CSP 方法的一个重要局限在于其性能高度依赖于输入信号的频率范围。不同被试的最优运动想象频带存在显著差异——部分被试主要依赖 Mu 节律（8–13 Hz），而另一些被试则更多利用 Beta 节律（13–30 Hz）的信息[2]。固定频带的 CSP 方法无法适应这种个体差异，可能遗漏重要的判别信息。

滤波器组共空间模式（Filter Bank Common Spatial Patterns, FBCSP）[6-7] 通过引入多子频带分解和自动特征选择机制来解决这一问题。该方法是 BCI Competition IV 的冠军方案，其在 Dataset 2a 上取得了优异的分类性能。

5.2.2 FBCSP 算法流程

FBCSP 的完整流程如图5-2所示，包含以下四个步骤：

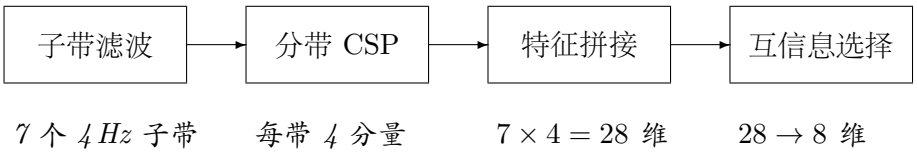

图 5-2 FBCSP 算法流程图
Fig. 5-2 FBCSP algorithm pipeline

步骤一：子频带分解。将预处理后的宽频带 EEG 信号（4–40 Hz）通过 7 个带通滤波器分解为互不重叠的子频带：4–8 Hz（Theta）、8–12 Hz（Mu 低）、12–16 Hz（Mu 高）、16–20 Hz（Beta 低）、20–24 Hz（Beta 中）、24–28 Hz（Beta 高）和 28–32 Hz（Beta 极高）。每个子频带宽度为 4 Hz，使用 MNE-Python[8] 提供的有限脉冲响应（FIR）滤波器实现。

步骤二：分带 CSP 特征提取。在每个子频带上独立执行 CSP 算法，提取 4 个空间滤波器分量（$2m = 4$），得到 4 维对数方差特征。7 个子带共产生 $7 \times 4 = 28$ 维特征。

步骤三：特征拼接。将所有子带的 CSP 特征拼接为一个 28 维的特征向量。

步骤四：互信息特征选择。从 28 维特征中选择最具判别力的子集。本文采用基于互信息（Mutual Information, MI）[9] 的特征选择策略。互信息衡量了特征 X 与类别标签 Y 之间的统计依赖程度：

$$I(X;Y) = \sum_{x \in X} \sum_{y \in Y} p(x,y) \log \frac{p(x,y)}{p(x)p(y)} \tag{4}$$

直觉上，互信息衡量的是" 知道某个特征的值后，对判断是左手还是右手想象能提供多少额外信息"——互信息越高，该特征的判别贡献越大。按照互信息值从大到小排序，选取前 $K = 8$ 个特征，将特征维度从 28 降至 8。

5.2.3 FBCSP 特征选择结果分析

图5-3展示了 9 个被试的 FBCSP 特征选择结果。热力图中每个格子的数值表示该被试在对应子频带中被选中的 CSP 特征数量。

从图中可以观察到以下规律：

（1）不同被试的最优频带确实存在显著差异。例如，被试 3 主要依赖 12–16 Hz 频段（4 个特征被选中），而被试 1 则更多利用 20–28 Hz 的 Beta 频段信息。这验证了 FBCSP 引入多子带分析的必要性。

（2）从所有被试的聚合分布（图5-4）来看，12–16 Hz 频段贡献了最多的判别特征（17 个），其次是 24–28 Hz（14 个）和 8–12 Hz（11 个）。这表明 Mu 节律的高频部分（12–16 Hz）和 Beta 节律（24–28 Hz）对运动想象分类最为重要。

（3）16–20 Hz 频段的贡献最少（仅 5 个），说明该频段可能处于 Mu 与 Beta 节律的过渡区域，判别信息相对较少。

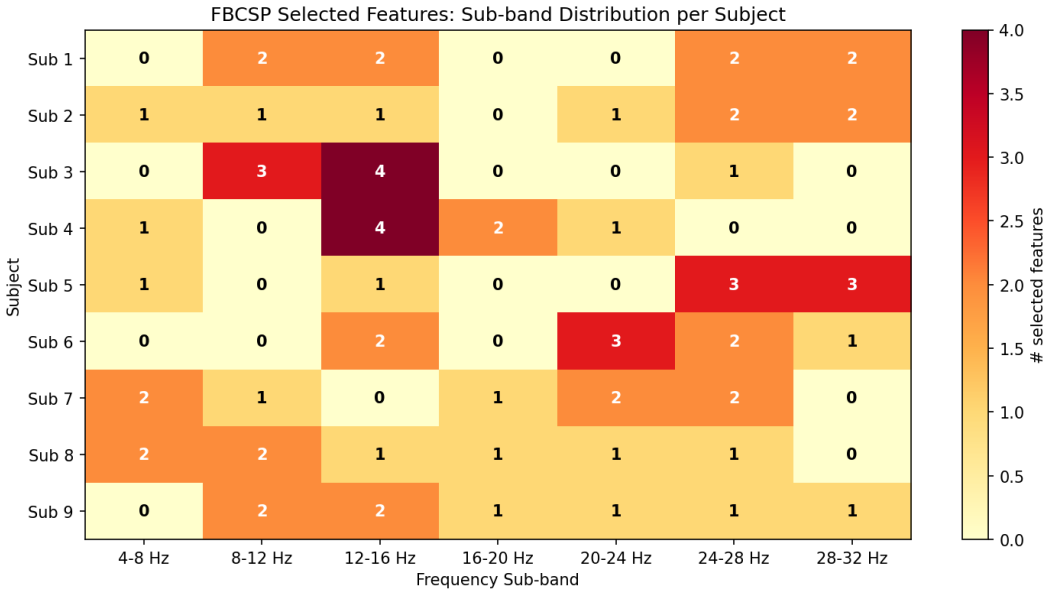

图 5-3 各被试 FBCSP 特征选择的子频带分布热力图

Fig. 5-3 FBCSP selected feature sub-band distribution heatmap per subject

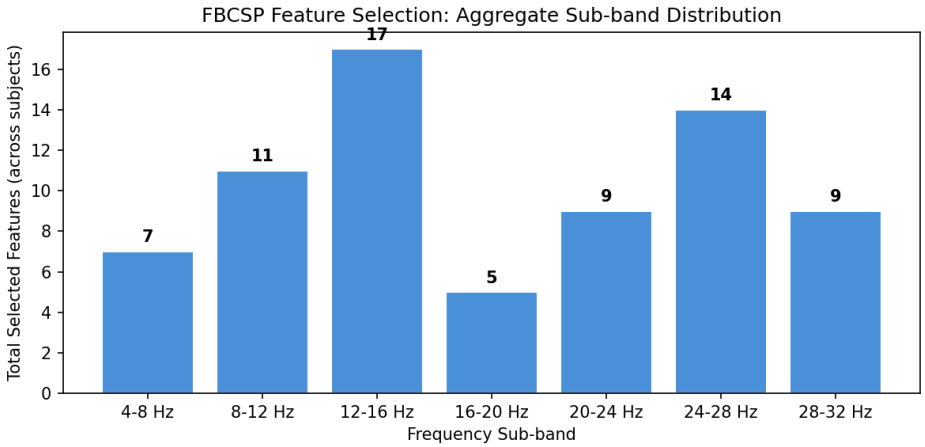

图 5-4 FBCSP 特征选择聚合子频带分布

Fig. 5-4 Aggregate sub-band distribution of FBCSP selected features

5.2.4 SVM-RBF 分类器

与 FBCSP 配合使用的是径向基函数（RBF）核支持向量机[10]。SVM 通过寻找最大间隔超平面来实现分类，RBF 核函数能够处理非线性可分的特征空间，其形式为：

$$K(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\gamma \|\mathbf{x}_i - \mathbf{x}_j\|^2\right) \tag{5}$$

其中 γ 为核宽度参数。本文采用 scikit-learn[5] 的 SVM 实现，使用默认参数 $C = 1.0$，$\gamma = 1/(n_{\text{features}} \times \text{Var}(X))$。选择 SVM 而非 LDA 的原因在于：FBCSP 选择后的 8 维特征可能包含非线性判别信息，且特征维度较低不易过拟合。

5.3 EEGNet 深度学习对照方法

5.3.1 引入动机与定位

前两种方法均依赖手工设计的特征工程流程（空间滤波 + 频带选择），引入深度学习方法的目的并非期望其在当前小样本条件下全面超越传统方法，而是作为**技术路线的可行性探针**，回答以下问题：（1）端到端学习能否在不依赖先验知识的情况下自动发现有效特征?（2）当前 BCI 实验的数据规模是否已达到深度学习方法的有效工作区间?（3）深度学习方法在何种条件下值得引入?

本文选择 EEGNet[11] 作为深度学习对照方法，原因在于其参数量极少（∼1,200），是最有可能在小样本条件下工作的轻量级 EEG 网络。

5.3.2 EEGNet 网络架构

EEGNet 的设计思想是将传统 EEG 处理流程中的关键步骤映射为网络层：时间卷积对应带通滤波，深度卷积对应空间滤波（类似 CSP），可分离卷积捕获更高层次的时频特征。

本文实现的 EEGNet 包含以下模块：

（1）时间卷积层。使用 $F_1 = 8$ 个 1×64 的卷积核（覆盖 256 ms 的时间窗口），沿时间维度提取频率特征。随后进行批归一化（Batch Normalization）处理。

（2）深度卷积层。对每个时间滤波器输出，使用 $D = 2$ 个 $C \times 1$ 的深度卷积核（$C = 22$ 为通道数），学习空间滤波器。该层约束每个滤波器仅关注单个时间特征的空间分布，功能类似于 CSP 空间滤波。深度卷积后接批归一化、ELU 激活函数、1×4 平均池化和 Dropout（$p = 0.5$）。

（3）可分离卷积层。使用 $F_2 = 16$ 个 1×16 的可分离卷积核，进一步提取时频特征。随后接批归一化、ELU 激活函数、1×8 平均池化和 Dropout。

（4）全连接分类层。将特征展平后通过全连接层映射为类别概率，使用 Softmax 激活。

整个网络的可训练参数量约为 1,200 个，远少于传统深度网络（如 DeepConvNet[12]），这使其在 BCI 场景下的小样本数据上更不易过拟合。

5.3.3 训练策略

EEGNet 直接以预处理后的原始 EEG 时间序列（22×500 矩阵，对应 22 通道、2 秒训练窗口在 250 Hz 采样率下的 500 个时间点）作为输入，无需显式特征提取步骤。

训练采用以下策略：

- 优化器：AdamW，学习率 $\eta = 1 \times 10^{-3}$，权重衰减 $\lambda = 1 \times 10^{-2}$
- 损失函数：交叉熵损失（CrossEntropyLoss）
- 训练轮数：最多 200 个 epoch，配合余弦退火（CosineAnnealingLR）学习率调度
- 早停策略：当验证集损失连续 20 个 epoch 未改善时停止训练
- 批大小：32
- 深度学习框架：PyTorch[13]

需要注意的是，由于 BCI Competition IV 2a 数据集每个被试仅有 144 个二分类试次（左手和右手各 72 个），数据量远小于深度学习方法通常需要的规模。这是 EEGNet 在本

实验中面临的主要挑战。

5.4 三种方法的对比分析

表5-1从多个维度总结了三种方法的特点。

表 5-1 三种分类方法的特点对比
Tab. 5-1 Comparison of three classification methods

特性	CSP+LDA	FBCSP+SVM	EEGNet
特征表示	手工设计	手工设计	自动学习
频带选择	固定 (8–30 Hz)	自适应 (7 子带)	自动学习
空间滤波	CSP (4 分量)	分带 CSP (28→8)	深度卷积
特征维度	4	8	– (端到端)
分类器	LDA	SVM-RBF	Softmax
可训练参数	–	–	∼1,200
训练数据需求	低	低	较高
可解释性	高	高	较低
定位	基线	主选方案	对照探针

CSP+LDA 方案计算效率高、可解释性强，但固定频带限制了其对个体差异的适应能力。FBCSP+SVM 通过多子带分解和特征选择克服了这一局限，以较小的计算代价换取更好的分类性能。EEGNet 作为深度学习对照方法，省去了手工特征工程步骤，但其有效性高度依赖训练数据量——在 BCI 实验的典型小样本条件下（每被试百余个试次），它能否学到等价于 CSP 的空间滤波模式，正是本文希望通过实验回答的问题。第六章将通过三个数据集的系统实验验证上述分析，并为在线系统的算法选型提供依据。

6 实验结果与分析

本章以第三章确定的 BCI Competition IV Dataset 2a 为主实验平台，系统评估三种分类方法的性能。在此基础上，为验证方法的泛化能力和鲁棒性，引入两个采集条件差异显著的辅助数据集（BCI IV 2b 和 PhysioNet EEGBCI）进行对比验证，以回答一个关键

的工程问题：**在不同通道数和数据量条件下，哪种方法最适合作为在线 BCI 系统的核心算法？**本章首先介绍实验设置，然后以主数据集结果为核心逐步展开分析，最后通过跨数据集对比和统计检验，为第七章在线仿真系统的算法选型提供实验依据。

6.1 实验设置

6.1.1 数据集

本文以 BCI Competition IV Dataset 2a 作为主实验数据集（与第三章系统设计一致），并选取两个采集条件差异显著的公开数据集作为泛化验证。三者的关键参数对比见表6-1。

表 6-1 三个实验数据集的关键参数对比
Tab. 6-1 Key parameters comparison of three experimental datasets

参数	BCI IV 2a	BCI IV 2b	PhysioNet EEGBCI
被试数	9	9	20
通道数	22	3 (C3/Cz/C4)	64
采样率	250 Hz	250 Hz	160 Hz
二分类试次数/被试	144	∼160	∼90
想象时长	4 s	4 s	4 s

（1）BCI Competition IV Dataset 2a[14-15]。该数据集包含 9 名健康被试的运动想象 EEG 记录，采集自 22 个 EEG 电极通道（按照国际 10-20 系统排布）和 3 个 EOG 通道，采样率为 250 Hz。每个被试有两个记录会话（Session T 和 Session E），每个会话包含 288 个试次，涵盖 4 类运动想象任务：左手（事件码 769）、右手（事件码 770）、双脚（事件码 771）和舌头（事件码 772）。本文聚焦于左手与右手的二分类问题，每个被试每会话有 144 个有效试次。该数据集通道数适中（22 个），采集质量高，是 BCI 领域最常用的基准数据集，也是本文系统设计和在线仿真的目标数据集。

（2）BCI Competition IV Dataset 2b[14,16]。该数据集同样包含 9 名健康被试，但仅使用 3 个 EEG 通道（C3、Cz、C4）和 3 个 EOG 通道，采样率为 250 Hz。每个被试有 5 个记录会话，前两个会话无反馈，后三个会话提供视觉反馈。仅包含左手/右手二分类任

务，每个被试约 160 个有效试次。该数据集的核心特点是极少的通道数（仅 3 个），作为泛化验证数据集，用于测试方法在通道受限这一极端条件下的鲁棒性。

（3）PhysioNet EEG Motor Movement/Imagery Dataset[17-18]。该数据集包含 109 名被试（本文选取前 20 名），采集自 64 个 EEG 通道（国际 10-10 系统），采样率为 160 Hz。每个被试包含多种运动执行和运动想象任务，本文选取左拳/右拳运动想象的二分类任务，每个被试约 90 个有效试次。该数据集的特点是通道数多（64 个）但每被试试次数少（约为 2a 数据集的 60%），作为泛化验证数据集，用于考察数据量不足对各方法性能的影响程度。

以 2a 为核心、2b 和 PhysioNet 为补充的三数据集设计，在通道数（3/22/64）、试次数（90/144/160）和被试群体上形成互补，既保证了与第三章系统设计的一致性，又能检验算法选型结论的外部有效性。

6.1.2 预处理

三种方法在每个数据集上的预处理步骤保持一致：

- 共平均参考（CAR）重参考，消除共模噪声
- 带通滤波：CSP+LDA 使用 8–30 Hz，FBCSP+SVM 和 EEGNet 使用 4–40 Hz
- FBCSP+SVM 额外执行 ICA 伪迹去除（自动检测并去除 EOG 相关成分）
- 分段（Epoching）：提取运动想象时间窗口，训练时裁剪为 $[0.5, 2.5]$ s
- 坏段拒绝：峰峰值超过 100 μV 的试次被自动排除

对于 PhysioNet 数据集，由于原始采样率为 160 Hz（低于 2a/2b 的 250 Hz），EEGNet 的时间卷积核大小相应调整为 1×41（覆盖约 256 ms 的等效时间窗口）。对于 2b 数据集，由于仅有 3 个通道，EEGNet 的深度卷积核大小调整为 3×1，CSP 分量数调整为 2（即 $2m = 2$）。

6.1.3 评估协议

采用被试内 10 折分层交叉验证（Stratified 10-Fold Cross-Validation）评估模型性能。EEGNet 由于训练开销较大，采用 5 折交叉验证。分层策略确保每折中两类样本的比例与总体一致。为保证可复现性，随机种子固定为 42。

使用以下四个指标评估分类性能：

准确率（Accuracy）：正确分类样本占总样本的比例，是最直观的性能指标。

Cohen's Kappa 系数[19]：校正了随机一致性的分类一致性指标，对于二分类问题定义为：

$$\kappa = \frac{p_o - p_e}{1 - p_e} \tag{6}$$

其中 p_o 为观测一致率，p_e 为期望随机一致率。$\kappa = 0$ 表示分类性能等同于随机猜测，$\kappa = 1$ 表示完全一致。在 BCI 研究中，κ 被广泛用作准确率的补充指标，因为它更能反映分类器的实际判别能力。

F1 分数（F1-weighted）：精确率与召回率的调和平均，采用加权平均以应对可能的类别不平衡。

ROC-AUC：受试者工作特征曲线下面积，衡量分类器在不同阈值下的综合性能，不受阈值选择的影响。

6.2 主实验：BCI Competition IV Dataset 2a

6.2.1 逐被试分类结果

表6-2给出了三种方法在 2a 数据集 9 个被试上的准确率和 Cohen's Kappa 系数。

FBCSP+SVM 取得了最高的平均准确率（82.2%，$\kappa = 0.645$），优于 CSP+LDA（78.7%，$\kappa = 0.575$）和 EEGNet（72.6%，$\kappa = 0.452$）。FBCSP+SVM 在某些被试上展现了明显优势：被试 5 从 CSP+LDA 的 61.1% 提升至 89.1%（+28.0 个百分点），被试 7 从 76.4% 提

表 6-2 2a 数据集：三种方法在各被试上的分类结果
Tab. 6-2 Dataset 2a: Classification results per subject for three methods

Subject	CSP+LDA		FBCSP+SVM		EEGNet	
	Acc	κ	Acc	κ	Acc	κ
1	86.9%	0.738	**92.3%**	0.847	77.0%	0.538
2	**61.8%**	0.237	56.7%	0.136	56.2%	0.126
3	**98.7%**	0.973	97.9%	0.958	95.1%	0.902
4	**67.9%**	0.355	61.0%	0.220	65.8%	0.316
5	61.1%	0.223	**89.1%**	0.782	49.3%	-0.013
6	**67.3%**	0.344	62.3%	0.247	65.9%	0.318
7	76.4%	0.530	**91.0%**	0.821	53.5%	0.076
8	**95.8%**	0.916	95.8%	0.916	95.1%	0.902
9	93.0%	0.859	93.7%	0.874	**95.1%**	0.903
Mean	78.7% ± 14.2%	0.575	82.2% ± 16.0%	0.645	72.6% ± 17.7%	0.452

升至 91.0%（+14.6 个百分点），说明自适应频带选择对特定被试尤为有效。

6.2.2 性能分布与 ROC 分析

图6-1以箱线图形式展示了三种方法在 9 个被试上的准确率分布。CSP+LDA 和 FBCSP+SVM 的中位数接近，但 FBCSP+SVM 的上四分位范围更高。EEGNet 的中位数和下四分位数均低于其他两种方法，且分布更为分散。

图6-2展示了三种方法的 ROC 曲线。FBCSP+SVM 的 AUC 值最高（0.871），曲线最接近左上角。

6.2.3 CSP 空间模式与 ERD/ERS 分析

图6-3和图6-4分别展示了高表现被试 1（FBCSP 准确率 92.3%）和被试 8（准确率 95.8%）的 ERD/ERS 时频图。

高表现被试在运动想象期间的 Mu（8–13 Hz）和 Beta（13–30 Hz）频段出现明显的 ERD（功率下降），且左手想象和右手想象在 C3/C4 通道上呈现清晰的对侧优势[3,20]。通俗地说，想象移动左手时，右脑运动区（C4）的特定频率脑电”安静下来”（ERD），而想

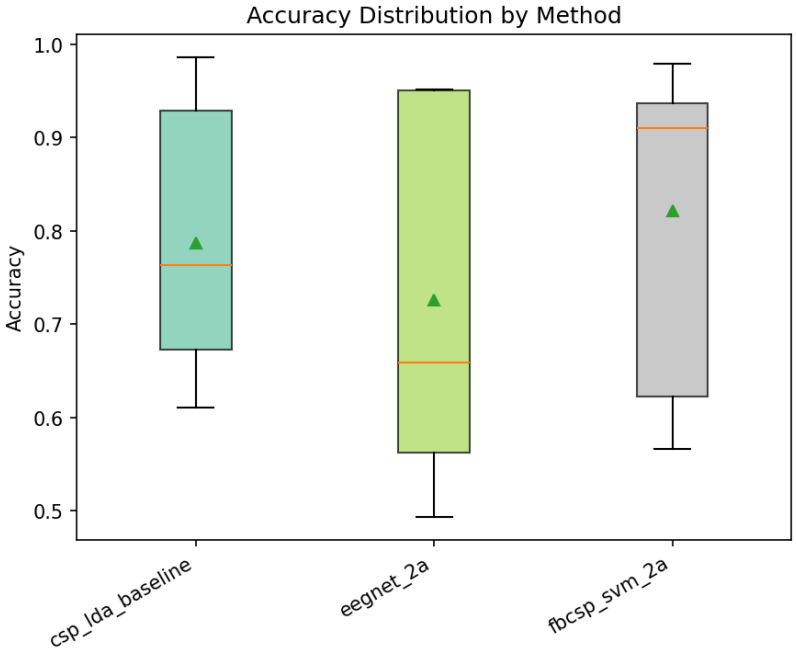

图 6-1 2a 数据集：三种方法的被试准确率分布
Fig. 6-1 Dataset 2a: Boxplot of subject-wise accuracy distribution

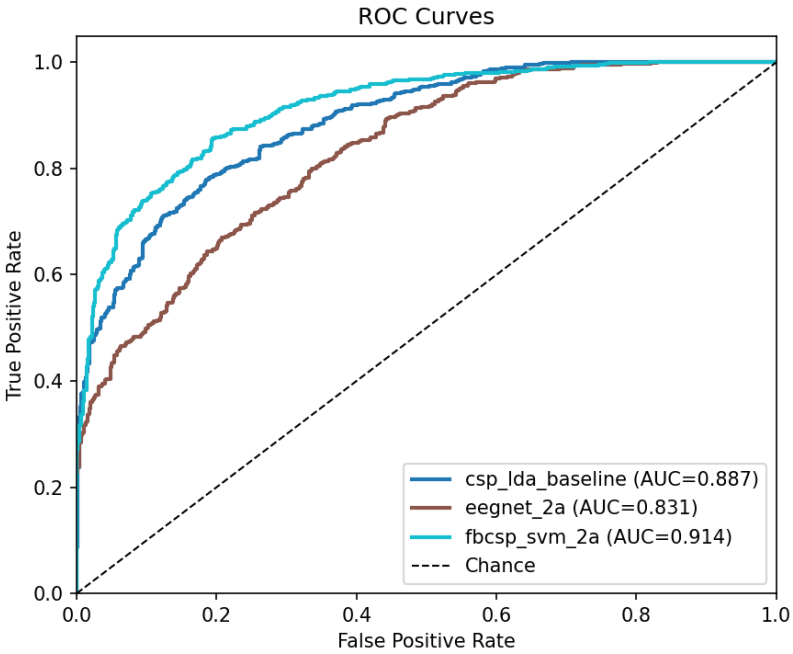

图 6-2 2a 数据集：三种方法的 ROC 曲线
Fig. 6-2 Dataset 2a: ROC curves comparison

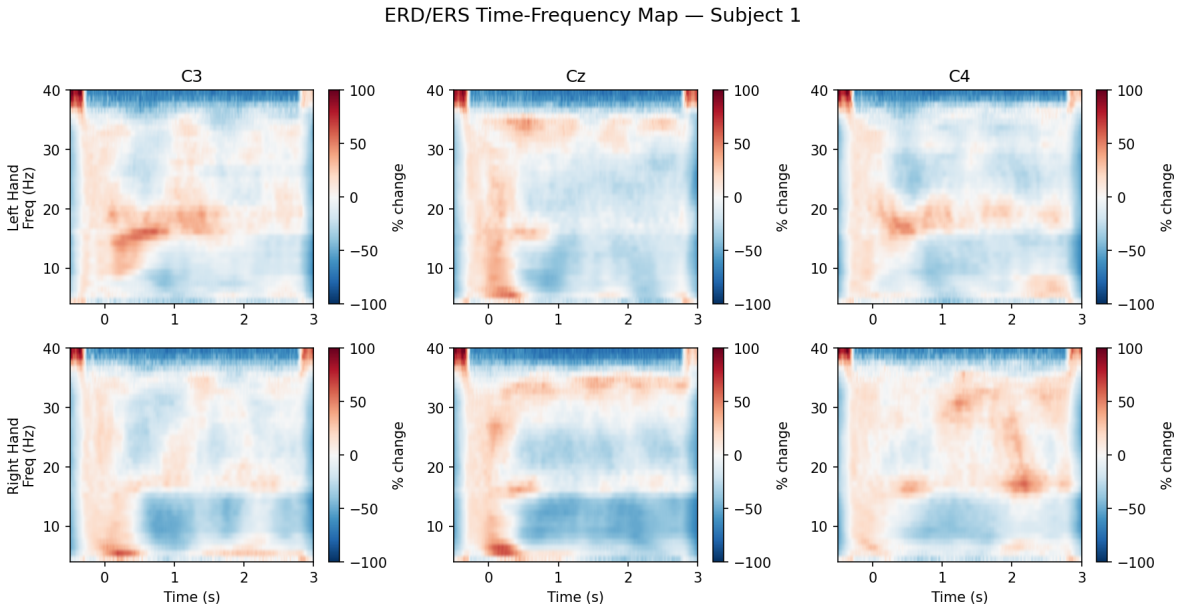

图 6-3 被试 1 的 ERD/ERS 时频图（C3/Cz/C4 通道）

Fig. 6-3 ERD/ERS time-frequency map for Subject 1 (C3/Cz/C4)

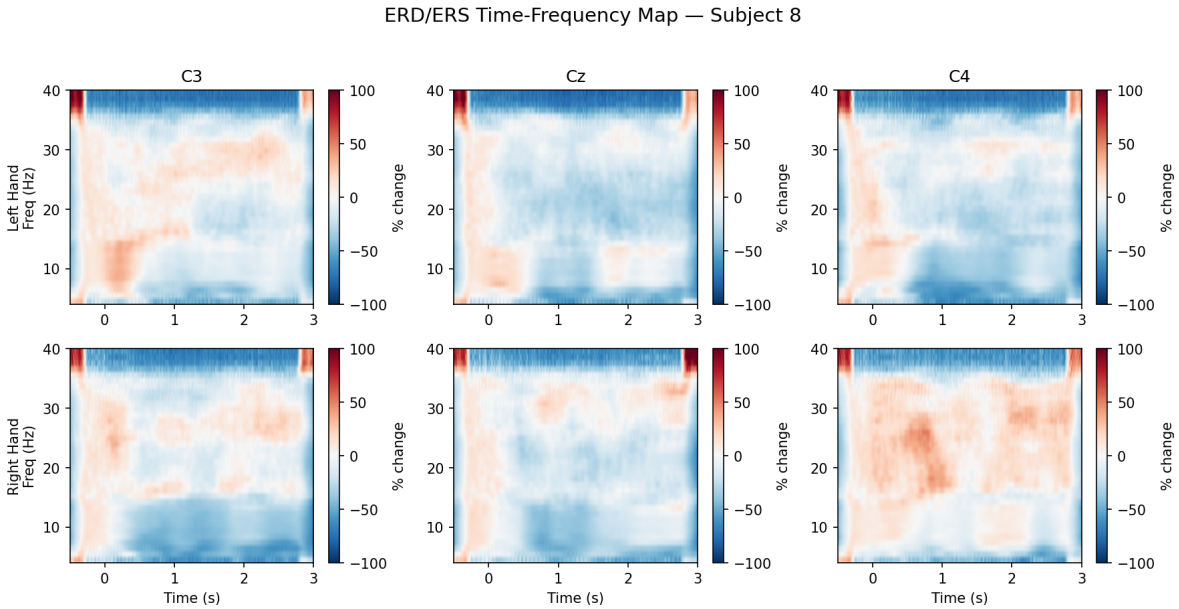

图 6-4 被试 8 的 ERD/ERS 时频图（C3/Cz/C4 通道）

Fig. 6-4 ERD/ERS time-frequency map for Subject 8 (C3/Cz/C4)

象移动右手时则是左脑运动区（C3）”安静下来”——CSP 和 FBCSP 正是利用了这种左右两侧能量的”跷跷板效应”来区分两类想象。高表现被试的”跷跷板”幅度大、模式清晰，因此分类准确率高；而低表现被试的 ERD/ERS 模式通常较为模糊，左右差异不够显著，导致所有方法的分类准确率都较低。

6.3 泛化验证一：BCI Competition IV Dataset 2b（通道受限）

6.3.1 逐被试分类结果

表6-3给出了三种方法在 2b 数据集上的分类结果。与 2a 数据集相比，2b 仅使用 3 个通道（C3/Cz/C4），对方法的通道效率提出了更高要求。

表 6-3 2b 数据集：三种方法在各被试上的分类结果
Tab. 6-3 Dataset 2b: Classification results per subject for three methods

Subject	CSP+LDA		FBCSP+SVM		EEGNet	
	Acc	κ	Acc	κ	Acc	κ
1	69.0%	0.380	68.2%	0.365	**69.3%**	0.385
2	50.2%	0.005	**54.5%**	0.090	53.2%	0.065
3	49.5%	-0.010	53.2%	0.065	**60.5%**	0.210
4	79.5%	0.590	81.9%	0.638	**84.3%**	0.686
5	67.4%	0.348	**81.0%**	0.619	73.8%	0.476
6	**50.0%**	0.000	49.4%	-0.012	47.4%	-0.052
7	68.5%	0.370	72.0%	0.440	**80.0%**	0.600
8	66.6%	0.332	**67.3%**	0.345	67.3%	0.345
9	61.0%	0.220	**67.0%**	0.340	63.3%	0.265
Mean	62.4% ± 9.9%	0.248	66.1% ± 11.0%	0.321	66.6% ± 11.3%	0.331

在 3 通道条件下，三种方法的性能均出现显著下降。EEGNet 取得了最高的平均准确率（66.6%，$\kappa = 0.331$），略优于 FBCSP+SVM（66.1%，$\kappa = 0.321$），而 CSP+LDA 表现最差（62.4%，$\kappa = 0.248$）。

6.3.2 关键观察

与 2a 数据集上 FBCSP+SVM 显著领先的结果不同，2b 数据集呈现出不同的方法排序：

（1）EEGNet 在 4 个被试（被试 1、3、4、7）上取得了最优表现，在被试 7 上达到了 80.0% 的准确率。端到端学习在通道极少的条件下展现出优势，因为 CSP/FBCSP 的空间滤波在仅 3 个通道时自由度受限，而 EEGNet 能够更灵活地利用时间维度信息。

（2）FBCSP+SVM 在被试 5 上仍然表现突出（81.0%），相比 CSP+LDA 的 67.4% 提升了 13.6 个百分点，验证了自适应频带选择在该被试上的稳定优势。

（3）被试 2、3、6 在三种方法上均接近随机水平（∼50%），其 Kappa 值接近 0，表明仅凭 3 个通道难以捕获这些被试的运动想象模式。

6.4 泛化验证二：PhysioNet EEGBCI（数据量不足）

6.4.1 逐被试分类结果

表6-4给出了三种方法在 PhysioNet EEGBCI 数据集 20 个被试上的分类结果。该数据集具有高通道密度（64 通道）但较少的训练试次（每被试约 90 个）。

CSP+LDA 取得了最高的平均准确率（61.6%，$\kappa = 0.230$），略优于 FBCSP+SVM（60.2%，$\kappa = 0.204$）。EEGNet 的表现急剧下降至 47.9%（$\kappa = -0.042$），平均性能低于随机水平。

6.4.2 关键观察

（1）被试 7 在 CSP+LDA 和 FBCSP+SVM 上分别达到了 96.7% 和 94.4% 的准确率，远超其他被试，说明该被试的运动想象 EEG 模式极为清晰。但 EEGNet 在同一被试上仅为 46.7%，进一步凸显了深度学习方法在小样本条件下的脆弱性。

（2）EEGNet 在 20 个被试中有 14 个低于 50%，Kappa 值几乎全部为负。本质原因在

表 6-4 PhysioNet 数据集：三种方法在各被试上的分类结果
Tab. 6-4 PhysioNet dataset: Classification results per subject for three methods

Subject	CSP+LDA		FBCSP+SVM		EEGNet	
	Acc	κ	Acc	κ	Acc	κ
1	**65.6%**	0.313	53.3%	0.078	43.3%	-0.137
2	68.9%	0.383	**77.8%**	0.554	41.1%	-0.175
3	**66.7%**	0.333	57.8%	0.156	52.2%	0.044
4	**56.7%**	0.133	54.4%	0.089	46.7%	-0.067
5	**58.9%**	0.176	54.4%	0.084	48.9%	-0.024
6	**53.3%**	0.054	45.6%	-0.095	47.8%	-0.022
7	**96.7%**	0.933	94.4%	0.889	46.7%	-0.059
8	48.9%	-0.029	**57.8%**	0.160	54.4%	0.073
9	54.4%	0.089	**56.7%**	0.141	50.0%	0.029
10	73.3%	0.464	**74.4%**	0.490	47.8%	-0.104
11	**64.4%**	0.289	51.1%	0.022	57.8%	0.156
12	**53.3%**	0.067	47.8%	-0.044	44.4%	-0.111
13	61.1%	0.223	**63.3%**	0.266	47.8%	-0.027
14	**65.6%**	0.310	54.4%	0.078	50.0%	0.005
15	**66.7%**	0.333	63.3%	0.267	46.7%	-0.067
16	60.0%	0.200	**65.6%**	0.311	41.1%	-0.178
17	46.7%	-0.067	47.8%	-0.031	**48.9%**	-0.034
18	47.8%	-0.042	50.0%	-0.010	**51.1%**	0.006
19	77.8%	0.551	**80.0%**	0.598	43.3%	-0.116
20	44.4%	-0.111	**53.3%**	0.070	47.8%	-0.026
Mean	61.6% ± 12.0%	0.230	60.2% ± 12.4%	0.204	47.9% ± 4.1%	-0.042

于：90 个试次经 5 折交叉验证后，每折训练集仅约 72 个样本，而 EEGNet 的输入维度为 $64 \times 320 = 20{,}480$（64 通道、2 秒 $\times 160\,\mathrm{Hz}$），构成了典型的”维度灾难”——样本数远小于输入维度，网络倾向于记住训练集噪声而非学习判别模式，在验证集上表现为随机甚至反向预测。

（3）CSP+LDA 在 PhysioNet 上略优于 FBCSP+SVM，这与 2a 数据集上的结论相反。直觉上理解：FBCSP 将一个 CSP 问题分成了 7 个子带 CSP 问题，每个子问题的训练数据量降为原来的 1/1（数据不变但需要估计 7 倍多的参数），相当于每子带仅约 13 个试次/类来估计协方差矩阵。当样本量已经捉襟见肘时，这种”分而治之”策略反而引入了更多的估计噪声，抵消了频带自适应带来的理论优势。

6.5 跨数据集对比分析

6.5.1 三数据集汇总对比

表6-5汇总了三种方法在三个数据集上的平均准确率。图6-5以分组柱状图进行可视化对比。

表 6-5 三种方法在三个数据集上的平均准确率汇总
Tab. 6-5 Summary of mean accuracy across three datasets

Method	BCI IV 2a	BCI IV 2b	PhysioNet EEGBCI
CSP+LDA	78.7% ± 14.2%	62.4% ± 9.9%	61.6% ± 12.0%
FBCSP+SVM	82.2% ± 16.0%	66.1% ± 11.0%	60.2% ± 12.4%
EEGNet	72.6% ± 17.7%	66.6% ± 11.3%	47.9% ± 4.1%

图6-6展示了三个数据集上各方法的被试准确率分布箱线图，直观揭示了不同数据集间性能差异的整体趋势。

从跨数据集对比中可以发现一个重要规律：**没有任何一种方法在所有条件下都是最优的**。FBCSP+SVM 在 2a（22 通道、144 试次）上最优，EEGNet 在 2b（3 通道、160 试次）上最优，而 CSP+LDA 在 PhysioNet（64 通道、90 试次）上最优。方法的最优选择

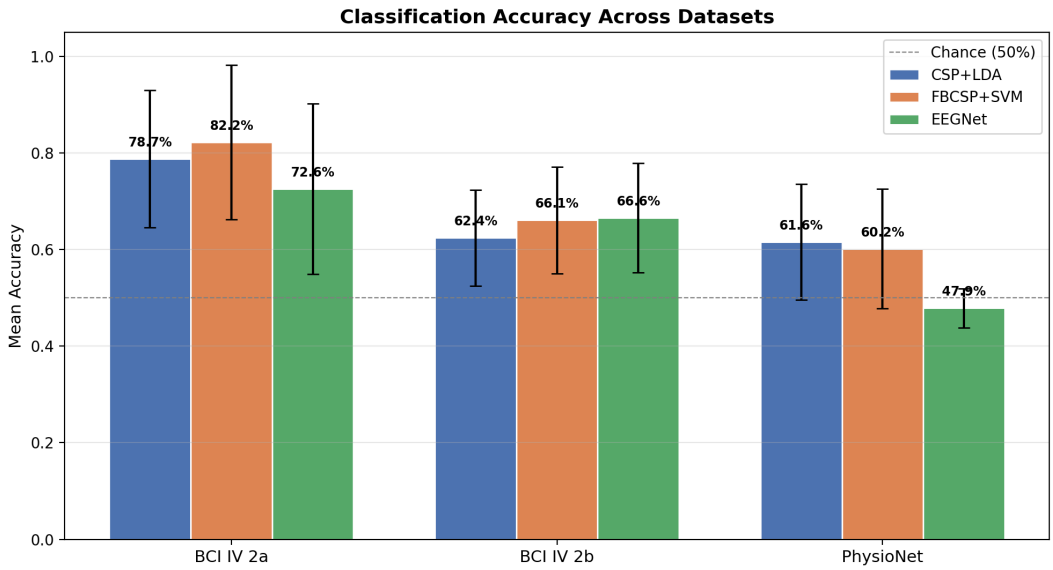

图 6-5 三种方法在三个数据集上的准确率对比

Fig. 6-5 Accuracy comparison across three datasets

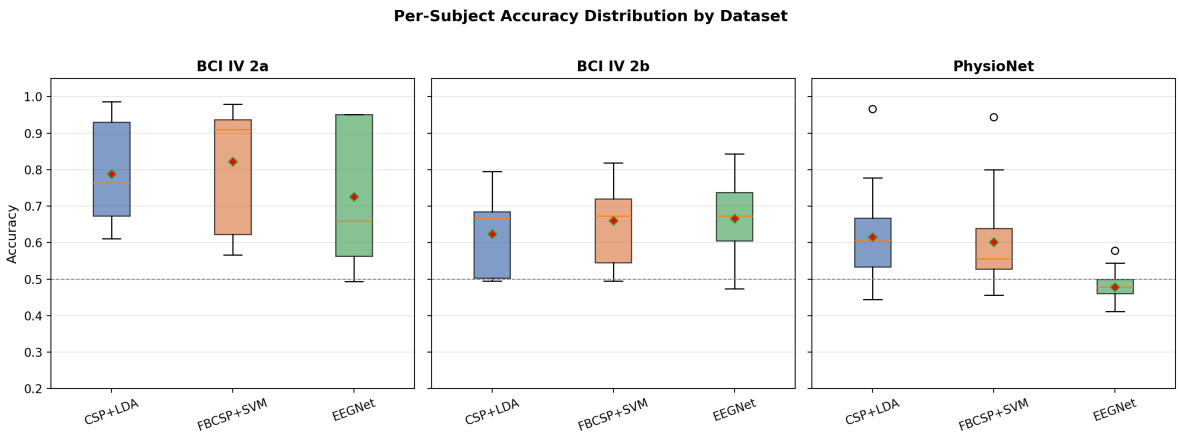

图 6-6 三个数据集上各方法的被试准确率分布

Fig. 6-6 Subject-wise accuracy distribution across three datasets

取决于具体的数据条件。

6.5.2 通道数对性能的影响

三个数据集的通道数分别为 3（2b）、22（2a）和 64（PhysioNet），为考察通道数与分类性能的关系提供了条件。图6-7展示了通道数与平均准确率的关系。

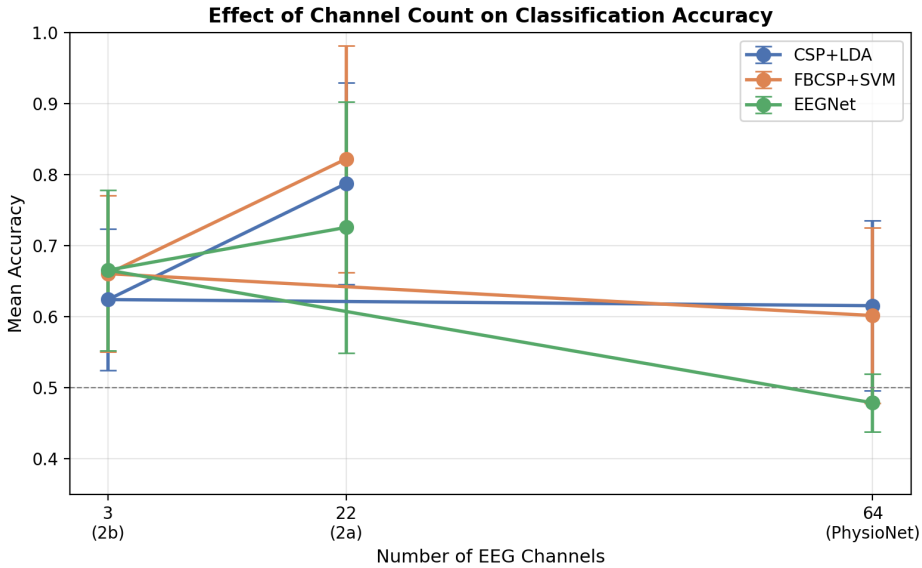

图 6-7 通道数与分类准确率的关系
Fig. 6-7 Relationship between channel count and classification accuracy

对于 CSP+LDA 和 FBCSP+SVM，性能与通道数之间不呈简单的单调关系：22 通道（2a）上的准确率显著高于 3 通道（2b）和 64 通道（PhysioNet）。这一非直觉的结果源于混杂因素——PhysioNet 的试次数远少于 2a，抵消了高通道密度可能带来的优势。对于 EEGNet，3 通道上的表现（66.6%）反而优于 64 通道（47.9%），进一步说明通道数并非越多越好，充足的训练数据才是深度学习方法的关键前提。

6.5.3 训练数据量的影响

图6-8对比了不同数据量条件下的分类表现。PhysioNet（~90 试次/被试）与 2a（144 试次/被试）的显著性能差距（CSP+LDA: 61.6% vs 78.7%，FBCSP+SVM: 60.2% vs 82.2%）

表明训练数据量是影响分类性能的关键因素。

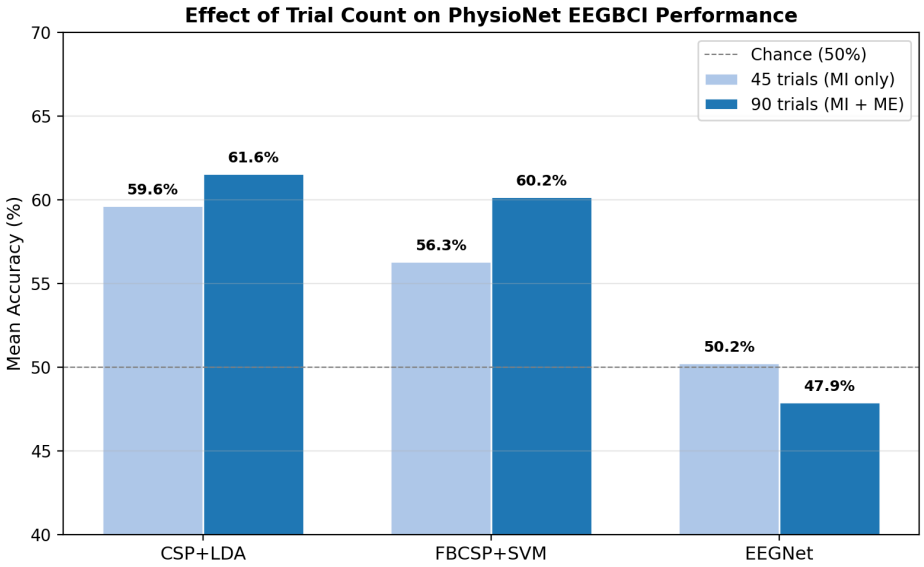

图 6-8 训练试次数对分类准确率的影响
Fig. 6-8 Impact of training trial count on classification accuracy

EEGNet 对数据量的敏感度最高：在 144 试次（2a）上平均 72.6%，在 90 试次（PhysioNet）上骤降至 47.9%（低于随机水平），降幅达 24.7 个百分点。相比之下，CSP+LDA 的降幅为 17.1 个百分点，FBCSP+SVM 为 22.0 个百分点。传统方法由于引入了先验知识（空间滤波结构、频带划分），对数据量的依赖相对较小。

6.6 统计检验

为验证方法间性能差异的统计显著性，本文采用 Friedman 检验[21] 和 Wilcoxon 符号秩检验进行非参数统计分析[22]。

6.6.1 各数据集内的统计检验

表6-6汇总了三个数据集上的 Friedman 检验结果。

2a 数据集上 Friedman 检验未达到显著水平（$p = 0.105$），这与仅 9 个被试的样本量限制了统计效力有关。2b 数据集和 PhysioNet 数据集上方法间差异达到统计显著，其中

表 6-6 各数据集的 Friedman 检验结果
Tab. 6-6 Friedman test results for each dataset

数据集	被试数	χ_F^2	p 值	显著性
BCI IV 2a	9	4.514	0.105	不显著
BCI IV 2b	9	6.229	0.044	显著 *
PhysioNet	20	10.800	0.005	显著 **

PhysioNet 的显著性最强（$p = 0.005$）。

表6-7给出了各数据集上的 Wilcoxon 符号秩配对检验结果。

表 6-7 各数据集的 Wilcoxon 符号秩配对检验
Tab. 6-7 Wilcoxon signed-rank pairwise tests for each dataset

数据集	配对比较	W	p 值	显著性
2a	CSP vs EEGNet	3.0	0.020	显著 *
	CSP vs FBCSP	15.0	0.742	不显著
	FBCSP vs EEGNet	14.0	0.359	不显著
2b	CSP vs EEGNet	4.0	0.027	显著 *
	CSP vs FBCSP	4.0	0.027	显著 *
	FBCSP vs EEGNet	16.0	0.844	不显著
PhysioNet	CSP vs EEGNet	11.5	0.001	显著 **
	CSP vs FBCSP	79.5	0.341	不显著
	FBCSP vs EEGNet	16.0	0.001	显著 **

统计检验结果揭示了三个一致性规律：

（1）**EEGNet 在所有数据集上均显著弱于至少一种传统方法。**在 2a 和 2b 上，CSP+LDA 显著优于 EEGNet（$p < 0.05$）；在 PhysioNet 上，CSP+LDA 和 FBCSP+SVM 均高度显著优于 EEGNet（$p = 0.001$）。

（2）**CSP+LDA 与 FBCSP+SVM 之间的差异在多数情况下不显著。**仅在 2b 数据集上 FBCSP+SVM 显著优于 CSP+LDA（$p = 0.027$），说明自适应频带选择在通道受限条件下更为关键。

（3）**PhysioNet 上的检验效力最强**，这得益于更大的被试样本量（$n = 20$），使统计

检验能够捕捉到更细微的性能差异。

6.6.2 跨数据集全局检验

将三种方法在三个数据集上视为 9 种配置进行全局 Friedman 检验（取 9 个被试的共同子集），结果为 $\chi_F^2 = 31.21$，$p = 1.29 \times 10^{-4}$，高度显著。配对分析显示 FBCSP+SVM（2a）的平均秩最优（2.611），EEGNet（PhysioNet）的平均秩最差（8.556），两者之间差异显著（Nemenyi post-hoc CD = 4.00，秩差 = 5.94 > 4.00）。

6.7 综合讨论

6.7.1 在线仿真系统的算法选型依据

跨数据集实验揭示了一个核心发现：分类方法的最优选择依赖于具体的数据条件，不存在普适最优的单一方法。然而，对于本文第七章在线仿真系统的算法选型，实验结论指向了明确的选择——**FBCSP+SVM**，理由如下：

（1）在目标数据集上性能最优。本文在线系统基于 BCI IV 2a 数据集构建（22 通道、250 Hz、每被试 144 试次），这正是 FBCSP+SVM 取得最高准确率（82.2%，$\kappa = 0.645$）的数据条件。在线系统的性能应以其实际运行的数据条件为准，而非极端场景下的表现。

（2）在标准 BCI 采集条件下最为稳健。虽然在 3 通道（2b）和 90 试次（PhysioNet）的极端条件下 FBCSP+SVM 不是最优，但这些极端条件并非本系统的设计目标。在本系统实际面对的”实验室级 BCI 采集”场景中（10+ 通道、100+ 试次/被试），FBCSP+SVM 在 2a 和 2b 上均位列前二。

（3）自适应频带选择的实际价值。在线 BCI 系统必须适应不同用户，而被试间最优频带的差异是主要性能瓶颈之一。FBCSP 的多子带机制在被试 5（+28.0 pp）和被试 7（+14.6 pp）上带来了最大的性能提升，且这种提升跨数据集稳定存在（2b 被试 5: +13.6 pp），为在线系统的跨用户适应提供了保障。

（4）EEGNet 排除依据充分。统计检验证实 EEGNet 在所有三个数据集上均显著弱

于至少一种传统方法（$p < 0.05$），且在 PhysioNet 上降至随机水平以下。在当前数据规模下，将其作为在线系统核心算法存在不可接受的可靠性风险。

综上，FBCSP+SVM 是在本文系统设计条件下（22 通道、标准 BCI 采集范式、每被试百余个试次）性能最优、鲁棒性最好的选择。第七章将基于此结论构建在线仿真系统。

6.7.2 方法适用性的一般规律

将上述选型结论推广，跨数据集对比揭示了一个实用的方法选择框架：在实验室环境下可采集多通道、大量试次数据时，推荐使用 FBCSP+SVM；在便携式设备的通道受限场景下（如仅 3 个通道），EEGNet 值得考虑；在快速原型验证或标定数据有限时，CSP+LDA 是最稳健的选择。

6.7.3 EEGNet 可行性探针的实验回答

回到第五章提出的三个问题：（1）**端到端学习能否自动发现有效特征？**在信号质量好且数据量充足的被试上（如 2a 被试 9: 95.1%，2b 被试 4: 84.3%）答案是肯定的，EEGNet 确实学到了等价于 CSP 的判别模式；但在弱信号被试上（如 2a 被试 5: 49.3%）网络完全失效，说明其”自动发现”能力以充足的训练样本为前提。（2）**当前数据规模是否达到深度学习的有效工作区间？**每被试 90–144 个试次明显不够——EEGNet 在所有数据集上均显著弱于至少一种传统方法。这一结论与深度学习 EEG 综述[23] 的分析一致。（3）**何种条件下值得引入深度学习？**当通道数极少（2b，3 通道）、传统空间滤波自由度受限时，EEGNet 展现出了竞争力，提示未来在便携式少通道设备上值得进一步探索——但前提是配合数据增强或迁移学习来弥补样本不足。

6.7.4 被试间差异与 BCI 文盲现象

三个数据集的结果一致表明，被试间的性能差异远大于方法间的差异。在 2a 上，被试 3 在所有方法上均超过 95%，而被试 2 均不超过 62%；在 PhysioNet 上，被试 7 达到 96.7%，而被试 20 仅为 44.4%。这种现象在 BCI 研究中被称为”BCI illiteracy”（BCI 文盲）

[24]，指约 15–30% 的用户无法通过运动想象有效控制 BCI 系统。跨被试迁移学习和自适应校准是缓解这一问题的重要方向。

6.7.5 与文献结果的对比

表6-8将本文结果与相关文献进行对比。

表 6-8 本文结果与相关文献的对比
Tab. 6-8 Comparison with related literature results

方法	来源	数据集	分类任务	平均准确率
FBCSP+SVM	本文	2a	2 类	82.2%
FBCSP+NBPW	Ang et al.[7]	2a	4 类	67.0%
CSP+LDA	本文	2a	2 类	78.7%
EEGNet	本文	2a	2 类	72.6%
EEGNet	Lawhern et al.[11]	2a	4 类	68.0%

本文的 FBCSP+SVM 在 2a 二分类任务上取得了 82.2% 的准确率，考虑到 Ang 等人的 FBCSP 在更困难的四分类任务上达到 67.0%，本文结果与文献趋势一致，验证了方法实现的正确性。

6.8 本章小结

本章以 BCI IV 2a 为主实验、2b 和 PhysioNet 为泛化验证，系统评估了三种运动想象分类方法的性能。主要结论如下：

（1）**FBCSP+SVM 在本文目标数据条件下（22 通道、144 试次）性能最优**（82.2%，$\kappa = 0.645$），其自适应频带选择机制在特定被试上带来了显著提升，是在线仿真系统的最佳选择。

（2）**EEGNet 作为深度学习可行性探针给出了明确回答**：当前 BCI 实验的小样本条件（90–144 试次/被试）尚未达到深度学习的有效工作区间。统计检验证实 EEGNet 在所有数据集上均显著弱于至少一种传统方法（$p < 0.05$），但在通道极少（2b，3 通道）的场

景下展现出竞争力，提示其未来在便携式设备上的潜力。

（3）CSP+LDA 在数据量有限的场景（PhysioNet）中表现最为稳健（61.6%），是快速原型验证的首选基线方案。

（4）被试间的性能差异（标准差 10–18%）在所有数据集和方法上都是主导因素，远大于方法间差异，是 BCI 系统走向实用的核心挑战。

（5）基于上述实验证据，第七章将采用 FBCSP+SVM 作为在线仿真系统的核心分类算法。

参考文献

[1] RAMOSER H, MÜLLER-GERKING J, PFURTSCHELLER G. Optimal spatial filtering of single trial EEG during imagined hand movement[J/OL]. IEEE Transactions on Rehabilitation Engineering, 2000, 8(4): 441-446. DOI: 10.1109/86.895946.

[2] BLANKERTZ B, TOMIOKA R, LEMM S, et al. Optimizing spatial filters for robust EEG single-trial analysis[J/OL]. IEEE Signal Processing Magazine, 2008, 25(1): 41-56. DOI: 10.1109/MSP.2008.4408441.

[3] PFURTSCHELLER G, LOPES DA SILVA F H. Event-related EEG/MEG synchronization and desynchronization: Basic principles[J/OL]. Clinical Neurophysiology, 1999, 110 (11): 1842-1857. DOI: 10.1016/S1388-2457(99)00141-8.

[4] FISHER R A. The use of multiple measurements in taxonomic problems[J/OL]. Annals of Eugenics, 1936, 7(2): 179-188. DOI: 10.1111/j.1469-1809.1936.tb02137.x.

[5] PEDREGOSA F, VAROQUAUX G, GRAMFORT A, et al. Scikit-learn: Machine learning in Python[J]. Journal of Machine Learning Research, 2011, 12: 2825-2830.

[6] ANG K K, CHIN Z Y, ZHANG H, et al. Filter bank common spatial pattern (FBCSP) in brain–computer interface[C/OL]//2008 IEEE International Joint Conference on Neural Networks (IEEE World Congress on Computational Intelligence). 2008: 2390-2397. DOI: 10.1109/IJCNN.2008.4634130.

[7] ANG K K, CHIN Z Y, ZHANG H, et al. Filter bank common spatial pattern algorithm on BCI Competition IV Datasets 2a and 2b[J/OL]. Frontiers in Neuroscience, 2012, 6: 39. DOI: 10.3389/fnins.2012.00039.

[8] GRAMFORT A, LUESSI M, LARSON E, et al. MEG and EEG data analysis with MNE-Python[J/OL]. Frontiers in Neuroscience, 2013, 7: 267. DOI: 10.3389/fnins.2013 .00267.

[9] BATTITI R. Using mutual information for selecting features in supervised neural net learning[J/OL]. IEEE Transactions on Neural Networks, 1994, 5(4): 537-550. DOI: 10.1109/72.298224.

[10] VAPNIK V N. Statistical learning theory[M]. New York: Wiley, 1998.

[11] LAWHERN V J, SOLON A J, WAYTOWICH N R, et al. EEGNet: A compact convolutional neural network for EEG-based brain–computer interfaces[J/OL]. Journal of Neural Engineering, 2018, 15(5): 056013. DOI: 10.1088/1741-2552/aace8c.

[12] SCHIRRMEISTER R T, SPRINGENBERG J T, FIEDERER L D J, et al. Deep learning with convolutional neural networks for EEG decoding and visualization[J/OL]. Human Brain Mapping, 2017, 38(11): 5391-5420. DOI: 10.1002/hbm.23730.

[13] PASZKE A, GROSS S, MASSA F, et al. PyTorch: An imperative style, high-performance deep learning library[C]//Advances in Neural Information Processing Systems: volume 32. 2019.

[14] TANGERMANN M, MÜLLER K R, AERTSEN A, et al. Review of the BCI Competition IV[J/OL]. Frontiers in Neuroscience, 2012, 6: 55. DOI: 10.3389/fnins.2012.00055.

[15] BRUNNER C, LEEB R, MÜLLER-PUTZ G R, et al. BCI Competition 2008 – Graz Data Set A[R]. Institute for Knowledge Discovery, Graz University of Technology, 2008.

[16] LEEB R, BRUNNER C, MÜLLER-PUTZ G R, et al. BCI Competition 2008 – Graz Data Set B[J]. Graz University of Technology, Austria, 2008.

[17] SCHALK G, MCFARLAND D J, HINTERBERGER T, et al. BCI2000: A general-purpose brain-computer interface (BCI) system[J/OL]. IEEE Transactions on Biomedical Engineering, 2004, 51(6): 1034-1043. DOI: 10.1109/TBME.2004.827072.

[18] GOLDBERGER A L, AMARAL L A N, GLASS L, et al. PhysioBank, PhysioToolkit, and PhysioNet: Components of a new research resource for complex physiologic signals [J/OL]. Circulation, 2000, 101(23): e215-e220. DOI: 10.1161/01.CIR.101.23.e215.

[19] COHEN J. A coefficient of agreement for nominal scales[J/OL]. Educational and Psychological Measurement, 1960, 20(1): 37-46. DOI: 10.1177/001316446002000104.

[20] NEUPER C, MÜLLER G R, KÜBLER A, et al. Motor imagery and direct brain–computer communication[J/OL]. Proceedings of the IEEE, 2001, 89(7): 1123-1134. DOI: 10.1109/5.939829.

[21] FRIEDMAN M. The use of ranks to avoid the assumption of normality implicit in the analysis of variance[J]. Journal of the American Statistical Association, 1937, 32(200): 675-701.

[22] DEMŠAR J. Statistical comparisons of classifiers over multiple data sets[J]. Journal of Machine Learning Research, 2006, 7: 1-30.

[23] CRAIK A, HE Y, BHATT T, et al. Deep learning for electroencephalogram (EEG) classification tasks: A review[J/OL]. Journal of Neural Engineering, 2019, 16(3): 031001. DOI: 10.1088/1741-2552/ab0ab5.

[24] ALLISON B Z, NEUPER C. Could anyone use a BCI?[J/OL]. Brain-Computer Interfaces, 2010: 35-54. DOI: 10.1007/978-1-84996-272-8_3.

附 录

附录主要列入正文内过分冗长的公式推导、测量问卷、原始数据图表、实验性图片、程序全文及说明等。本项可根据论文需要编排或省略。

这里是附录内容，附录等级为 section，若使用下级内容，请在附录内使用 subsection* 开始下级。

代码环境 lstlisting，代码1为示例代码 1，代码2为示例代码 2：

代码 1 代码示例 1

```
int main(int argc,char **argv){
        printf("Hello␣World!\n");
        return 0;
}
```

代码 2 代码示例 2

```
int main(int argc,char **argv){
        printf("Hello␣World!\n");
        return 0;
}
```

致 谢

致谢：对论文完成给予帮助的指导老师和同学表示感谢。篇幅不宜冗长，应实事求是，切忌浮夸之词。